

Analyse et Fouille de Données Correction Exercice 2 –ACP Non Normée --	 Auditoire: D-LSI-ADBD A-U: 2025-2026
---	--

Enoncé :

Soit le tableau de données suivant :

	Informatique	Gestion
Noam	4	5
Jean	6	7
Li	8	0

Où les lignes représentent les individus (noms de quelques étudiants) et les colonnes les variables (notes en informatique et gestion). Ce tableau de données peut être représenté par la matrice X de données brutes :

$$X = \begin{pmatrix} 4 & 5 \\ 6 & 7 \\ 8 & 0 \end{pmatrix}$$

1. Calculer la matrice $M = X - \bar{X}$ des données centrées.
2. Calculer la matrice $C(X)$ des covariances de X .
3. Vérifier que $\lambda_1 = 10.152$ et $\lambda_2 = 1.188$ sont deux valeurs propres associées à $C(X)$.
Puis vérifier que les vecteurs unitaires :

$$V_1 = \begin{pmatrix} -0.407 \\ 0.914 \end{pmatrix} \text{ et } V_2 = \begin{pmatrix} 0.914 \\ 0.407 \end{pmatrix}$$

sont les vecteurs propres de $C(X)$ associés à λ_1 et λ_2 respectivement.

4. À partir des résultats précédents, déterminer les deux composantes principales de l'ACP du nuage des individus associé au tableau X . Pour chacun de ces axes, préciser le pourcentage de la quantité d'information projetée sur l'axe considéré, et le pourcentage cumulé.
5. Déterminer la matrice des scores des individus.
6. Calculer la saturation des variables et interpréter le cercle de corrélation.

Correction :

1.

$$\overline{X_{(1)}} = \frac{18}{3} = 6 \quad \overline{X_{(2)}} = \frac{12}{3} = 4$$

$$M = X - \bar{X} = \begin{pmatrix} -2 & 1 \\ 0 & 3 \\ 2 & -4 \end{pmatrix}$$

2. La matrice de covariances :

Théorème de König-Huygens :

$$\text{Var}(X_{(j)}) = \left(\frac{1}{n} \|X_{(j)}\|^2 \right) - \overline{X_{(j)}}^2$$

$$\text{Cov}(X_{(i)}, X_{(j)}) = \left(\frac{1}{n} \langle X_{(i)}, X_{(j)} \rangle \right) - \overline{X_{(i)}} \overline{X_{(j)}}$$

Ou $C(X) = \frac{1}{n} M^t M$

$$\text{Var}(x_1) = \frac{4^2 + 6^2 + 8^2}{3} - 6^2 = 2.67 \quad \text{ou} \quad \text{Var}(x_1) = \frac{(-2)^2 + 0^2 + (2)^2}{3} = 2.67$$

$$\text{Var}(x_2) = \frac{5^2 + 7^2 + 0^2}{3} - 4^2 = 8.67 \quad \text{ou} \quad \text{Var}(x_2) = \frac{(1)^2 + 3^2 + (-4)^2}{3} = 8.67$$

$$\text{Cov}(x_1, x_2) = \frac{(4 \times 5) + (6 \times 7) + (8 \times 0)}{3} - (6 \times 4) = -3.33 \quad \text{ou} \quad \text{Cov}(x_1, x_2) = \frac{((-2) \times 1) + (0 \times 3) + (2 \times (-4))}{3} = -3.33$$

$$C(X) = \begin{pmatrix} 2.67 & -3.33 \\ -3.33 & 8.67 \end{pmatrix}$$

3. La matrice de covariances C de taille $p \times p$, carrée et symétrique, alors elle admet p valeurs propres et p vecteurs propres associés, tels que :

$$C V_j = \lambda_j V_j$$

Dans notre exemple à deux variables, C admet 2 valeurs propres et 2 vecteurs propres tels que soit vérifié les égalités suivantes :

$$\begin{pmatrix} 2.67 & -3.33 \\ -3.33 & 8.67 \end{pmatrix} \begin{pmatrix} v_{11} \\ v_{12} \end{pmatrix} = \lambda_1 \begin{pmatrix} v_{11} \\ v_{12} \end{pmatrix}$$

$$\begin{pmatrix} 2.67 & -3.33 \\ -3.33 & 8.67 \end{pmatrix} \begin{pmatrix} v_{21} \\ v_{22} \end{pmatrix} = \lambda_2 \begin{pmatrix} v_{21} \\ v_{22} \end{pmatrix}$$

I) Détermination des valeurs propres

Résolution de l'équation $\det(C - \lambda I) = 0$

$$C - \lambda I = \begin{pmatrix} 2.67 & -3.33 \\ -3.33 & 8.67 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$C - \lambda I = \begin{pmatrix} 2.67 - \lambda & -3.33 \\ -3.33 & 8.67 - \lambda \end{pmatrix}$$

$$\det(C - \lambda I) = (2.67 - \lambda)(8.67 - \lambda) - 3.33^2 = 0$$

$$\lambda^2 - 11.34\lambda + 12.06 = 0$$

$$\Delta = b^2 - 4ac = 80.3556$$

$$\lambda_1 = \frac{-b + \sqrt{\Delta}}{2a} = 10.152$$

$$\lambda_2 = \frac{-b - \sqrt{\Delta}}{2a} = 1.188$$

II) Détermination des vecteurs propres

V_1 ?

Résolution du système d'équations $CV_1 - \lambda_1 V_1 = 0$

$$\begin{cases} 2.67 \times v_{11} - 3.33 \times v_{12} - 10.152 \times v_{11} = 0 \\ -3.33 \times v_{11} + 8.67 \times v_{12} - 10.152 \times v_{12} = 0 \end{cases} \quad (I)$$

Une solution possible est le vecteur unitaire :

$$v_{11}^2 + v_{12}^2 = 1$$

Prenons l'équation : $2.67 \times v_{11} - 3.33 \times v_{12} - 10.152 \times v_{11} = 0$ du système (I)
 $-7.482 \times v_{11} - 3.33 \times v_{12} = 0 \rightarrow v_{11} = -0.445 \times v_{12}$

Remplacer dans : $v_{11}^2 + v_{12}^2 = 1$

$$0.445^2 v_{12}^2 + v_{12}^2 = 1 \rightarrow \text{Solution possible : } v_{12} = 0.914 \quad v_{11} = -0.407$$

Donc :

$$V_1 = \begin{pmatrix} -0.407 \\ 0.914 \end{pmatrix}$$

V_2 ?

Résolution du système d'équations $CV_2 - \lambda_2 V_2 = 0$

$$\begin{cases} 2.67 \times v_{21} - 3.33 \times v_{22} - 1.188 \times v_{21} = 0 \\ -3.33 \times v_{21} + 8.67 \times v_{22} - 1.188 \times v_{22} = 0 \end{cases} \quad (II)$$

Une solution possible est le vecteur unitaire :

$$v_{21}^2 + v_{22}^2 = 1$$

Prenons l'équation : $2.67 \times v_{21} - 3.33 \times v_{22} - 1.188 \times v_{21} = 0$ du système (II)
 $1.482 \times v_{21} - 3.33 \times v_{22} = 0 \rightarrow v_{21} = 2.247 \times v_{22}$

Remplacer dans : $v_{21}^2 + v_{22}^2 = 1$

$$2.247^2 v_{22}^2 + v_{22}^2 = 1 \rightarrow \text{Solution possible : } v_{22} = 0.407 \quad v_{21} = 0.914$$

Donc :

$$V_2 = \begin{pmatrix} 0.914 \\ 0.407 \end{pmatrix}$$

4. En appliquant le théorème spectral pour les matrices symétriques, nous diagonalisons la matrice des variances : $C(X) = QDQ^t$ tel que:

$$Q = \begin{pmatrix} -0.407 & 0.914 \\ 0.914 & 0.407 \end{pmatrix} : \text{Matrice des deux composantes principales de l'ACP}$$

$$\text{et } D = C(Y) = \begin{bmatrix} 10.152 & 0 \\ 0 & 1.188 \end{bmatrix} : \text{Matrice des variances des données dans le nouveau repère (CP}_1, \text{CP}_2)$$

$$\lambda_1 + \lambda_2 = \text{Var}(x_1) + \text{Var}(x_2)$$

$$10.152 + 1.188 = 2.67 + 8.67 = 11.34$$

	Valeur propre	Pourcentage	Pourcentage cumulé
CP₁	10.152	89,524	89,524
CP₂	1.188	10,476	100

5.

$$Y = (X - \bar{X}) Q = M Q = \begin{bmatrix} -2 & 1 \\ 0 & 3 \\ 2 & -4 \end{bmatrix} \times \begin{bmatrix} -0.407 & 0,914 \\ 0,914 & 0,407 \end{bmatrix} = \begin{bmatrix} 1.728 & -1.42 \\ 2.742 & 1.221 \\ -4.47 & 0.2 \end{bmatrix}$$

6. Saturation des variables : Corrélation entre les données des anciennes et des nouvelles variables.

$$r(X_{(j)}, Y_{(k)}) = \frac{q_{jk} \sqrt{\lambda_k}}{\sqrt{\text{Var}(X_{(j)})}}$$

	Y₍₁₎	Y₍₂₎
Informatique X₍₁₎	-0.794	0.61
Gestion X₍₂₎	0,989	0,151

